Deep Learning Session 5

1. **Efek Regularisasi pada Batch Normalization (Slide 6–8)**
   Slide 8 menyebutkan bahwa Batch Normalization *"acts like mild regularization"* dan *"often eliminates the need for Dropout"*.
   - Jelaskan mekanisme statistik mini-batch yang menimbulkan efek regularisasi tersebut.
   - Uraikan kondisi atau skenario spesifik ketika asumsi "menghilangkan Dropout" ini tidak lagi berlaku atau justru dapat memicu instabilitas pelatihan.

   Jawaban: Batch Normalization (BatchNorm) bekerja dengan menormalisasi aktivasi berdasarkan mean dan variance dari setiap mini-batch sebelum diteruskan ke layer berikutnya. Nilai mean dan variance tersebut dihitung dari data yang berbeda pada setiap mini-batch, sehingga nilai normalisasi dapat sedikit berubah antar-batch. Variasi ini memberikan efek regularisasi ringan yang dapat membantu mengurangi overfitting (Ioffe & Szegedy, 2015). Fungsi utama BatchNorm adalah menstabilkan proses training, sedangkan efek regularisasi menjadi manfaat tambahannya. BatchNorm tidak selalu cukup untuk menggantikan Dropout karena keduanya memiliki mekanisme berbeda. Dropout menonaktifkan sebagian neuron secara acak selama training, sedangkan BatchNorm melakukan normalisasi aktivasi. Dataset kecil dengan risiko overfitting tinggi dapat tetap membutuhkan Dropout sebagai regularisasi tambahan. Ukuran mini-batch yang sangat kecil juga dapat membuat perhitungan mean dan variance kurang akurat sehingga training menjadi kurang stabil. (Session 5, Slide 6-8; Ioffe & Szegedy, 2015).

2. **Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)**
   Mengapa penambahan kedalaman lapisan pada plain CNN (tanpa sambungan residual) justru menurunkan akurasi pelatihan (degradation problem), padahal secara teoritis representasi model yang lebih dalam minimal dapat menyamai model dangkal via fungsi identitas (identity mapping)?
   - Jelaskan bagaimana skip connection mengubah formulasi aliran gradien saat propagasi balik (backpropagation).
   - Hubungkan mekanisme tersebut dengan mitigasi fenomena vanishing gradient yang telah dibahas pada Sesi 02.

   Jawaban: Penambahan layer pada plain CNN tidak selalu meningkatkan hasil model. Jaringan yang semakin dalam justru dapat mengalami degradation problem, yaitu akurasi training menurun. Secara teori, layer tambahan seharusnya dapat mempertahankan hasil dari jaringan yang lebih dangkal dengan mempelajari fungsi identitas. Pada praktiknya, proses belajar menjadi lebih sulit karena gradient dapat semakin melemah ketika diteruskan dari layer akhir ke layer awal. Kondisi ini disebut vanishing gradient dan dapat membuat layer awal sulit belajar (Session 01, Slide 19-20). Skip connection membantu dengan membuat jalur langsung dari input ke output. Pada residual block, output dirumuskan sebagai $y = F(x) + x$, sehingga gradient memiliki jalur langsung melalui x

selain melalui $F(x)$. Mekanisme ini membantu gradient mengalir ke layer sebelumnya, sehingga mengurangi risiko vanishing gradient dan membuat jaringan yang lebih dalam lebih mudah dilatih (Session 05, Slide 10-12; He et al., 2016).

3. **Feature Extraction vs. Fine-Tuning (Slide 14–16)**
   Bandingkan pendekatan Feature Extraction (membekukan backbone) dengan Fine Tuning (membuka sebagian atau seluruh lapisan) ditinjau dari empat dimensi:
   - Jumlah parameter yang diperbarui (trainable parameters).
   - Kebutuhan volume data latih.
   - Beban komputasi dan memori per epoch.
   - Risiko rusaknya fitur representasi bawaan (destructive gradient updates).
   - Sintesiskan kriteria praktis kapan masing-masing pendekatan paling tepat dipilih.

   Jawaban: Feature Extraction dilakukan dengan membekukan semua layer pretrained dan hanya melatih classifier baru. Jumlah parameter yang diperbarui menjadi lebih sedikit sehingga proses training lebih ringan dan lebih hemat memori. Cara ini cocok ketika jumlah data latih terbatas karena sebagian besar fitur sudah dipelajari dari dataset sebelumnya. Fine-Tuning dilakukan dengan membuka sebagian atau beberapa layer dari model pretrained untuk ikut dilatih. Jumlah parameter yang diperbarui menjadi lebih banyak sehingga membutuhkan komputasi dan memori lebih besar. Fine-Tuning juga memiliki risiko lebih tinggi untuk mengubah fitur yang sudah dipelajari jika learning rate terlalu besar. Karena itu, learning rate yang lebih rendah digunakan saat Fine-Tuning (Session 05, Slide14–16). Feature Extraction lebih cocok digunakan sebagai langkah awal pada dataset kecil. Fine-Tuning dapat dipilih ketika data yang tersedia lebih banyak atau fitur dari model pretrained belum cukup sesuai dengan data baru (PyTorch, 2025).

4. **Kaidah Penerapan Data Augmentation (Slide 20, 21, 23)**
   - Jelaskan pertimbangan metodologis mengapa pipeline data augmentation hanya diaktifkan pada train set dan harus dinonaktifkan pada validation/test set.
   - Berikan satu contoh teknik transformasi citra **yang tidak layak digunakan** untuk klasifikasi ras hewan peliharaan (pet breeds), dan jelaskan argumentasi ketidaklayakannya berdasarkan invariansi semantik label.

   Jawaban: Data augmentation hanya diterapkan pada training set karena bertujuan menambah variasi data yang digunakan model untuk belajar dan meningkatkan generalisasi. Transformasi seperti flip, rotation, crop, dan color jitter membuat model melihat variasi gambar yang berbeda. Validation dan test set tidak diberi augmentation agar evaluasi dilakukan pada data yang tidak dimodifikasi. Jika augmentation diterapkan pada validation atau test, hasil evaluasi dapat dipengaruhi oleh transformasi acak dan kurang merepresentasikan performa model pada data sebenarnya (Session 05, Slide 20, 21, 23).

   Contoh transformasi yang tidak layak untuk klasifikasi ras adalah vertical flip. Membalik hewan secara vertikal membuat posisi hewan menjadi terbalik dan tidak realistis. Walaupun label ras tetap sama, gambar hasil transformasi tidak lagi memiliki kondisi

visual yang wajar. Augmentation seharusnya mempertahankan invariansi semantik, yaitu perubahan gambar tidak mengubah makna atau labelnya.

5. **Mitigasi Catastrophic Forgetting (Slide 28–29)**
   Slide 28 mengingatkan potensi terjadinya *catastrophic forgetting* apabila proses adaptasi model berlangsung terlalu agresif.
   - Uraikan bagaimana fenomena hilangnya representasi bawaan tersebut terjadi.
   - Jelaskan dua strategi mitigasi konkret (misalnya *differential learning rate, gradual unfreezing*, atau *linear warmup*) beserta alasan teoritis mengapa strategi tersebut efektif.

   Jawaban: Catastrophic forgetting terjadi ketika model pretrained menyesuaikan diri terlalu cepat dengan data baru. Perubahan pada bobot model yang terlalu besar dapat membuat fitur yang sudah dipelajari sebelumnya ikut berubah atau hilang. Akibatnya, model dapat kehilangan informasi dari model pretrained yang masih berguna untuk tugas baru.

   Differential learning rate dapat digunakan dengan memberikan learning rate yang lebih kecil pada bagian model pretrained. Perubahan pada fitur yang sudah ada menjadi lebih perlahan dan terkendali. Gradual unfreezing dilakukan dengan membuka layer model sedikit demi sedikit untuk ikut dilatih. Model memiliki waktu untuk menyesuaikan fitur lama dengan data baru tanpa mengubahnya secara drastis. Kedua strategi ini membantu mempertahankan fitur dari model pretrained selama proses fine-tuning. (Session 05, Slide 28-29).

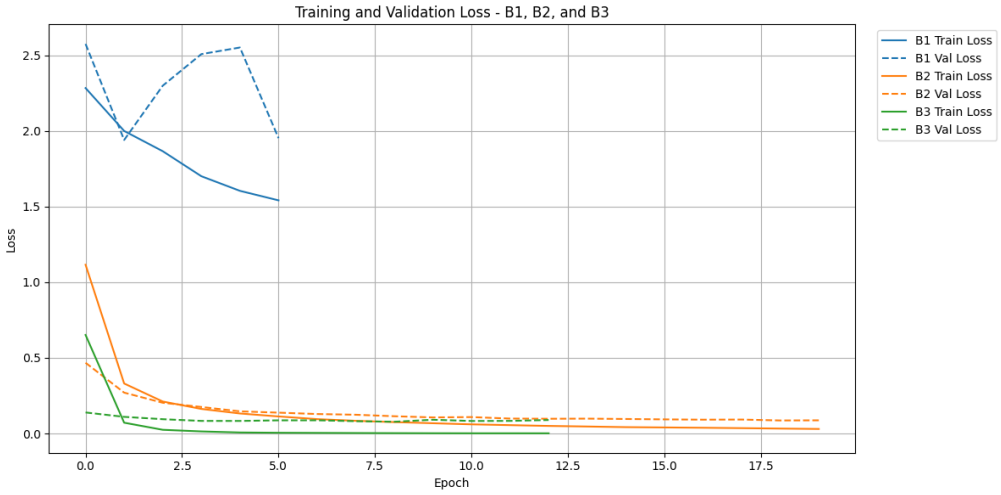
C1. Tabel Konsolidasi dan Visualisasi Pembelajaran

C1.1 Tabel Komparatif Eksperimen B1-B5

Experiment	Strategy	Trainable Parameters	Learning Rate	Best Epochs	Training Time (s)	Validation Accuracy at Best Loss	Test Macro F1
B5	EfficientNet-B0 Feature Extraction, No Augment	12810	0.001	20	185.093	0.9900	0.9833
B4a	Feature Extraction, No Augmentation	5130	0.001	20	183.255	0.9799	0.9601
B4b	Feature Extraction, With Augmentation	5130	0.001	19	267.524	0.9799	0.9537
B3	Progressive Fine-Tuning	8398858	layer4: 1e-4, fc: 1e-3	9	117.634	0.9732	0.9497
B2	Feature Extraction	5130	0.001	19	181.623	0.9799	0.9466
B1	Training from Scratch	11181642	0.001	2	63.277	0.2910	0.2253

Tabel menunjukkan bahwa model Feature Extraction (B2) memberikan performa lebih baik daripada Training from Scratch (B1) dimana test Macro F1 meningkat karena menggunakan pretrained weights. Progressive Fine-Tuning (B3) hanya sedikit meningkatkan Macro F1 dibandingkan B2 meskipun jumlah trainable parameters meningkat. Pada B4, model tanpa augmentasi (B4a) memperoleh Macro F1 lebih tinggi daripada model dengan augmentasi (B4b), juga membutuhkan waktu training lebih singkat. B5 mencapai hasil terbaik karena menggunakan EfficientNet-B0, dimana mencapai Macro F1 98,33% dengan 12.810 trainable parameters dan waktu pelatihan 185,093 detik. Hasil ini menunjukkan bahwa B5 memberikan performa terbaik di antara model yang diuji.

C1.2. Grafik Training Loss vs. Validation Loss B1-B3



Grafik menunjukkan bahwa B1 memiliki training dan validation loss yang fluktuatif sehingga model belum mampu mempelajari pola data dengan benar. B2 menunjukkan penurunan loss bertahap yang menandakan bahwa model semakin baik dalam mempelajari data. B3 mengalami penurunan training loss yang lebih cepat hingga mendekati nol, yang berarti B3 dapat menyesuaikan diri dengan data pelatihan lebih cepat dibandingkan B1 dan B2. Secara keseluruhan, B2 dan B3 menunjukkan proses pembelajaran yang lebih baik daripada B1, dengan B3 mencapai nilai training loss terendah dalam jumlah epoch yang lebih sedikit.

C2. Pembahasan Analisis Komparatif

C2.1. Alasan terjadi d*-isparitas performa yang tajam antara pelatihan dari nol (B1) dengan paradigma transfer learning (B2 & B3)

Perbedaan performa antara B1 dan B2–B3 menunjukkan bahwa penggunaan pretrained weights membantu model dalam belajar. B1 harus mempelajari seluruh fitur gambar dari awal, sedangkan B2 dan B3 memanfaatkan fitur yang telah dipelajari dari ImageNet. Pretrained model membuat model lebih mudah mengenali pola, terutama saat dataset terbatas.

Hasil pengujian menunjukkan bahwa B1 memperoleh test Macro F1 sebesar 22,53%, sedangkan B2 mencapai 94,66% dan B3 mencapai 94,97%. B2 menggunakan feature extraction dengan freezing seluruh backbone, sedangkan B3 membuka layer4 dan fc agar model dapat menyesuaikan fitur dengan dataset baru. Peningkatan Macro F1 pada B3 hanya sebesar 0,31 poin dibandingkan B2. Hasil ini menunjukkan bahwa transfer learning memberikan peningkatan performa yang besar, sedangkan fine-tuning tambahan belum memberikan peningkatan yang signifikan pada eksperimen ini.

C2.2. Trade-off performa vs. stabilitas antara feature extraction murni dan fine-tuning bertahap pada volume data terbatas

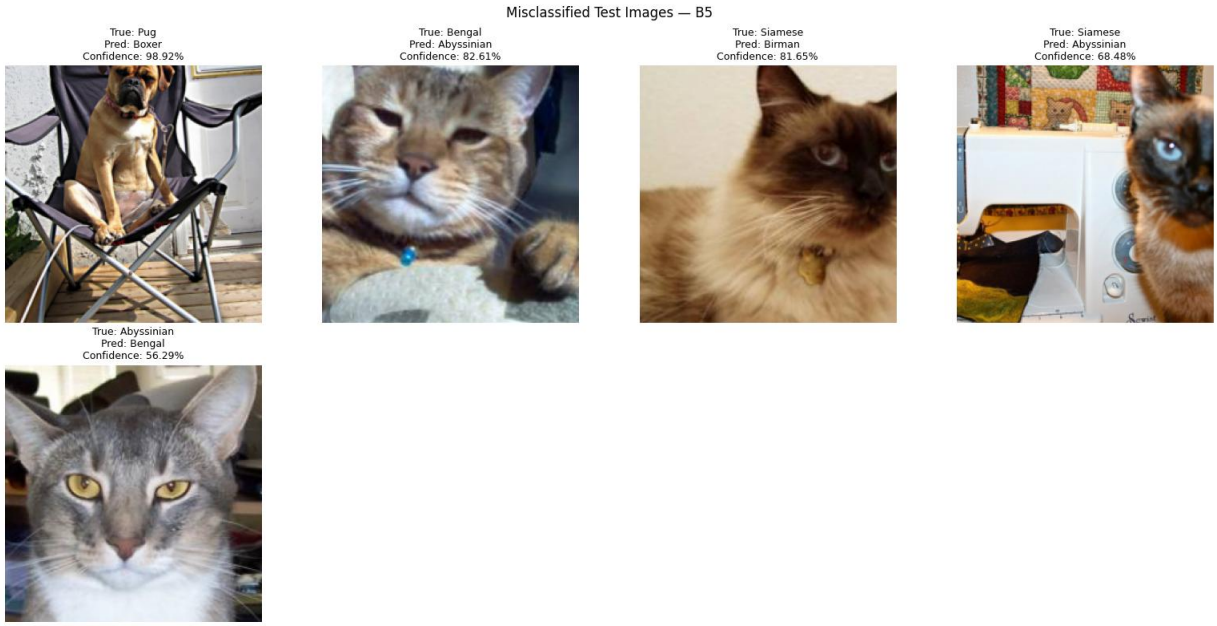
Pada dataset terbatas, feature extraction cenderung lebih stabil karena weight pretrained backbone tetap dipertahankan dan hanya classifier yang dilatih. B2 memperoleh test Macro F1 sebesar 94,66% dengan 5.130 trainable parameters, sehingga kebutuhan trainingnya relatif lebih sederhana. Fine-tuning bertahap pada B3 memungkinkan penyesuaian fitur terhadap dataset baru

dengan melatih layer4 dan fc. Test Macro F1 meningkat menjadi 94,97%, tetapi jumlah trainable parameters bertambah menjadi 8.398.858. Peningkatan performa yang hanya sebesar 0,31 poin menunjukkan bahwa additional computational cost belum memberikan keuntungan yang sebanding. Pada eksperimen ini, feature extraction menghasilkan keseimbangan yang lebih baik antara performa, stabilitas, dan efisiensi training.

C2.3. Peran augmentasi (B4) dalam meredam overfitting

Pada eksperimen Feature Extraction (B4), penerapan data augmentasi (B4b) belum menunjukkan peran meredam overfitting jika dibandingkan B4a tanpa augmentasi. B4b memperoleh Test Macro F1 sebesar 95,37%, sedikit lebih rendah daripada B4a sebesar 96,01%. Kedua model memiliki validation accuracy sebesar 97,99%, sehingga augmentasi belum memberikan peningkatan pada performa validasi. Kondisi tersebut berkaitan dengan strategi Feature Extraction, yaitu seluruh backbone dibekukan dan hanya classifier head dengan 5.130 trainable parameters yang dilatih. Augmentasi berupa rotasi dan color jitter menambah variasi gambar training, tetapi belum menghasilkan peningkatan mengenal data baru pada eksperimen ini. Selain itu, waktu pelatihan B4b meningkat dari 183,255 detik menjadi 267,524 detik.

C3. Failure Analysis (Analisis Kasus Misklasifikasi)



Ground Truth	Prediksi	Confidence	Hipotesis Penyebab Kesalahan
Pug	Boxer	98,92%	Gambar yang tercatat sebagai Pug secara visual justru lebih menyerupai Boxer. Ketidaksesuaian antara isi gambar dan label ground truth mengindikasikan kemungkinan adanya kesalahan pelabelan (label noise) pada dataset. Model memprediksi Boxer dengan confidence sebesar 98,92%, sehingga prediksi tersebut justru tampak

			sesuai dengan karakteristik visual gambar. Kasus ini menunjukkan bahwa kesalahan prediksi yang tercatat belum tentu sepenuhnya disebabkan oleh model, tetapi juga dapat dipengaruhi oleh kualitas label pada dataset.
Bengal	Abyssinian	82,61%	Gambar menunjukkan kucing dengan bulu oranye-putih, pola garis pada wajah, dan mata yang menyipit. Ciri Bengal yang paling mudah dikenali biasanya berupa pola bintik pada tubuh, tetapi bagian tubuh pada gambar tidak terlihat jelas. Model mungkin lebih banyak mengandalkan warna bulu dan karakteristik wajah daripada pola bulu khas Bengal.
Siamese	Birman	81,65%	Gambar yang tercatat memiliki label ground truth Siamese secara visual lebih menyerupai Birman. Model memprediksi kelas Birman dengan confidence sebesar 81,65%, sehingga hasil prediksi tersebut tampak sesuai dengan pengamatan visual secara manual. Ketidaksesuaian antara label ground truth dan karakteristik gambar mengindikasikan kemungkinan adanya kesalahan pelabelan (label noise) pada dataset.
Siamese	Abyssinian	68,48%	Gambar menunjukkan karakteristik wajah yang masih menyerupai Siamese, tetapi warna bulunya memiliki kemiripan dengan Abyssinian. Perbedaan antara ciri wajah dan warna bulu tersebut mungkin memengaruhi model dalam menentukan kelas, sehingga gambar diprediksi sebagai Abyssinian dengan confidence sebesar 68,48%, meskipun label ground truth-nya adalah Siamese. Kasus ini menunjukkan bahwa kemiripan pada aspek visual tertentu, seperti warna bulu dapat memengaruhi hasil klasifikasi meskipun karakteristik lainnya lebih menyerupai kelas sebenarnya.
Abyssinian	Bengal	56,29%	Gambar dengan label ground truth Abyssinian diprediksi sebagai Bengal dengan confidence sebesar 56,29%. Berdasarkan pengamatan visual, bentuk telinga pada gambar lebih menyerupai Abyssinian, sedangkan corak pada wajah memiliki kemiripan dengan Bengal. Perbedaan karakteristik visual tersebut mungkin menjadi salah satu faktor yang memengaruhi prediksi model. Nilai confidence sebesar 56,29% juga

			menunjukkan bahwa probabilitas prediksi model terhadap kelas Bengal tidak terlalu dominan.

Analisis lima gambar yang salah diklasifikasikan menunjukkan bahwa kemiripan karakteristik visual, seperti pola wajah, warna bulu, dan bentuk telinga, mungkin memengaruhi prediksi model. Beberapa sampel juga menunjukkan kemungkinan ketidaksesuaian label ground truth dengan karakteristik gambar, meskipun dugaan label noise perlu diverifikasi melalui anotasi asli dataset. Hasil tersebut menunjukkan bahwa evaluasi kesalahan klasifikasi perlu mempertimbangkan karakteristik visual gambar, tingkat confidence, dan accuracy label dataset.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

B5 (EfficientNet-B0 Feature Extraction) menjadi strategi yang direkomendasikan karena memperoleh test accuracy dan Macro F1 sebesar 98,33%, dengan 12.810 trainable parameters dan waktu pelatihan 185,093 detik. Strategi ini sesuai untuk skenario data terbatas ketika membutuhkan performa klasifikasi tinggi tanpa harus melatih seluruh parameter model. Penggunaan pretrained weights membantu model memanfaatkan fitur yang telah dipelajari sebelumnya, sedangkan proses pelatihan hanya berfokus pada classifier. Penerapan tetap perlu mempertimbangkan ketersediaan pretrained weights, kemampuan perangkat, ukuran model, latensi prediksi, dan penggunaan memori agar sesuai dengan kebutuhan operasional.

Eksperimen memiliki beberapa keterbatasan. Pengujian hanya menggunakan satu random seed, sehingga kestabilan hasil pada pembagian data yang berbeda belum diketahui. Dataset juga hanya mencakup 10 kelas dari Oxford-IIIT Pet, sehingga performa model belum tentu sama pada kelas lain atau gambar dari kondisi nyata yang lebih beragam. Eksperimen lanjutan perlu membandingkan training loss dan validation loss untuk mendeteksi kemungkinan overfitting, mengulang eksperimen dengan beberapa random seed, serta menguji model pada data yang lebih beragam. Pemeriksaan gambar yang salah diklasifikasikan dan validasi label juga diperlukan untuk mengetahui apakah kesalahan berasal dari model, kemiripan karakteristik visual, atau kemungkinan ketidaktepatan label dataset sebelum model diterapkan di lingkungan produksi.

Referensi

Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. *Proceedings of the 32nd International Conference on Machine Learning*, 448–456. https://proceedings.mlr.press/v37/ioffe15.html

He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep residual learning for image recognition*. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770–778. https://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html

PyTorch. (2025). *Transfer Learning for Computer Vision Tutorial*. PyTorch Tutorials. https://docs.pytorch.org/tutorials/beginner/transfer_learning_tutorial.html

BINUS University. *Session 01: Deep Learning Foundations*, Slide 19-20

BINUS University. *Session 05: Advanced CNNs and Transfer Learning*,

Pernyataan Penggunaan AI

1. **Nama Model/Alat AI yang Digunakan**
   ChatGPT OpenAI.
2. **Ruang Lingkup Bantuan AI**
   ChatGPT digunakan sebagai alat bantu selama pengerjaan tugas, terutama dalam pemahaman konsep CNN dan transfer learning, meminta penjelasan mengenai code PyTorch, menelaah kemungkinan penyebab error, serta memperbaiki kejelasan dan struktur penulisan laporan. Bantuan AI juga digunakan untuk mendiskusikan pemahaman metrik evaluasi dan kemungkinan penyebab kesalahan klasifikasi. Saran yang diberikan tidak langsung dianggap benar, tetapi disinkronkan dengan implementasi dan hasil eksperimen yang didapat.
3. **Verifikasi Keluaran AI**
   Kode dan konfigurasi eksperimen diperiksa melalui running langsung pada notebook. Angka yang dicantumkan dalam laporan dicocokkan dengan hasil evaluasi model dan log eksperimen. Penjelasan konsep diperiksa kembali menggunakan materi perkuliahan dan referensi yang relevan. Interpretasi hasil serta kesimpulan akhir ditinjau berdasarkan bukti eksperimen. Penjelasan mengenai penyebab kesalahan klasifikasi dianggap sebagai kemungkinan terlebih dahulu apabila belum dapat dipastikan, kemudian memverifikasinya secara mandiri.